Rapport d'activité - SAE 15 - Nathan Mantion

Dans le cadre de la SAE 1.5 - Traiter des donnés, j'ai été amené à mener un projet de collecte, stockage et traitement de données.

Lecture du sujet

A la lecture du sujet, on remarque qu'il faudra produire un outil qui permettra les choses suivantes

- Collecte des données
    - Données des parkings
    - Données des vélos
    - Données du tramway
- Stockage des données
    - Traduire les fichier xml des parkings en donnés stockables et réutilisables
    - De même pour les fichiers Json des vélos
    - De même pour le tramway
- Mise en forme des données
- Traitement des données
    - Permettre un affichage des données en fonction de plusieurs paramètres temporels
        - date de début
        - date de fin
        - laps de temps
    - Permettre un affichage sur un plan géographique de la ville (à faire si le temps le permets)

Pour l'instant, nous garderons l'interprétation des données pour l'humain, il n'est pas exclu qu'un programme pouvant interpréter les données soit codé

Acquisition des données

En regardant les données disponibles sur le site Open Data Montpellier, on voit que les données en rapport avec le tramway ne peuvent pas nous donner d'informations sur leur utilisation, nous ne pouvons avoir que des informations géographiques qui nous serviront pour le traitement et l'interpretation. Pour rendre mon code utilisable uniquement avec les programmes, je chosis tout de même d'ajouter une fonction pour récupérer le fichier contenant les informations sur les stations de tramway de la ville. Je profite de cette fonction pour prendre les mêmes informations sur les station veloMag. Pour les parkings automobiles, les informations n'existent pas sur le site de l'agglomération, je vais alors créer un fichier .csv manuellement.

Parkings automobiles

```
def getPark(idPark:str,path="."):

response=requests.get(f"https://data.montpellier3m.fr/sites/default/files/ressources/
{idPark}.xml") #Acquision du fichier xml du parking grâce à la variable idPark qui
```

```
renseigne l'identifiant du parking
    file=open(f"{path}/{idPark}_{int(time.time())}.xml","w+", encoding="UTF-8")
#Création d'un fichier pour stocker le contenu du fichier .xml téléchargé, si
l'utilisateur veut enregistrer le fichier dans un répertoire particulier, il peut
renseigner la variable ``path`` par défaut, la fonction sauvergarde le fichier dans
le même répertoire que le programme
    file.write(response.text) #Ecriture du ficher
    file.close() #Fermeture de l'instance de fichier
    return file.name #On retourne le chemin du fichier.
```

Parkings veloMag

```
def getVelo(path="."):
    response=requests.get("https://montpellier-fr-
smoove.klervi.net/gbfs/en/station_status.json") #Acquisition du fichier json
représentant l'état de toutes les stations velaMag
    file=open(f"{path}/veloMag_{int(time.time())}.json","w+", encoding="UTF-
8")#Création d'un fichier pour stocker le contenu du fichier .json téléchargé, si
l'utilisateur veut enregistrer le fichier dans un répertoire particulier, il peut
renseigner la variable ``path`` par défaut, la fonction sauvergarde le fichier dans
le même répertoire que le programme
    file.write(response.text) #Ecriture du fichier
    file.close() #Fermeture de l'instance du fichier
    return file.name #On retourne le chemin du ficher
```

Emplacement des parkings veloMag et des stations de Tramway

```
def getInfos(path="."):
    #Dictionnaire contenant les URLs des stations liés au moyen de transport
    urls =
{"tram":"https://data.montpellier3m.fr/sites/default/files/ressources/MMM_MMM_ArretsT
ram.json","veloMag":"https://montpellier-fr-
smoove.klervi.net/gbfs/en/station_information.json"}
    files=[] #Liste qui contiendra les deux fichiers d'informations récupérés
    for key in urls.keys: #Boucle pour les deux urls
        response=requests.get(urls[key]) #Récupération du fichier
        file=open(f"{path}/{key}.json","w+", encoding="UTF-8") #Création des fichiers
.json avec les informations
        file.write(response.text) #Ecriture du fichier
        file.close() #Fermeture de l'instance du fichier
        files.append(file.name)#On ajoute le chemin d'accès au fichier dans la liste
    return files #On retourne la liste contenant les deux fichiers
```

Emplacement des parkings automobile

A l'aide de Google Maps et de la liste des parkings sur le site d'Open Data Montpellier, j'ai récupéré manuellement les coordonnées GPS des parkings dont nous pouvons traiter les données afin de les utiliser lors du traitement et donc de l'interprétation des données.

Mise en forme des données

Pour faciliter les passages entre fichiers, base de données et programmes de traitement des données, j'ai choisi de créer de nouvelles classes, une par type de station

- Une classe `parking` contenant :
    - Un attribut `time` de type `int` donnant l'heure de la prise d'information en secondes depuis epoch UNIX
    - Un attribut `parkID` de type `str` donnant l'identifiant du parking
    - Un attribut `open`de type booléen donnant l'état d'ouverture du parking (True pour ouvert, False pour fermé)
    - Un attribut `free` de type `int` donnant le nombre de places libres dans le parking
    - Un attribut `total` de type `int` donnant le nombre de places totales dans le parking
- Une classe `velo` contenant :
    - Un attribut `time` de type `int` donnant l'heure de la prise d'information en secondes depuis epoch UNIX
    - Un attribut `id` de type `int` donnant l'identifiant de la station
    - Un attribut `bikes`de type `int` donnant le nombre de vélos disponibles
    - Un attribut `dis` de type `int` donnant le nombre de vélos indisponilbes mais garés à la station
    - Un attribut `free`de type `int` donnant le nombre de places disponibles à la station

Elles sont définies avec les codes suivants

Classe `parking`

```
class parking:
    def __init__(self,parkID,open,free,total):
        self._time=int(time.time())
        self._parkID=parkID
        self._open=open
        self._free=free
        self._total=total

    #défintion des getter et setters des attributs
    @property
    def time(self):
        return self._time
    @time.setter
    def time(self,time):
        #check si time est bien un entier
        if type(time) == int:
            self._time == time
        else:
            raise TypeError("time type must be an int !")


    @property
    def parkID(self):
        return self._parkID
```

```
    @parkID.setter
    def parkID(self,parkID):
        #check si parkID est bien dans les id disponibles sur le site opendata
        if parkID in
['FR_MTP_ANTI','FR_MTP_COME','FR_MTP_CORU','FR_MTP_EURO','FR_MTP_FOCH','FR_MTP_GAMB',
'FR_MTP_GARE','FR_MTP_TRIA','FR_MTP_ARCT','FR_MTP_PITO','FR_MTP_CIRC','FR_MTP_SABI','
FR_MTP_GARC','FR_CAS_SABL','FR_MTP_MOSS','FR_STJ_SJLC','FR_MTP_MEDC','FR_MTP_OCCI','F
R_CAS_VICA','FR_MTP_GA109','FR_MTP_GA250','FR_CAS_CDGA','FR_MTP_ARCE','FR_MTP_POLY']:
            self._parkID=parkID
        else:
            raise ValueError("parkID is not valid !")

    @property
    def open(self):
        return self._open
    @open.setter
    def open(self,open):
        #check si open est bien un booléen
        if type(open)==bool:
            self._open=open
        else:
            raise TypeError("open type must be a bool !")

    @property
    def free(self):
        return self._free
    @free.setter
    def free(self,free):
        #check si free est bien un int
        if type(free) == int:
            self._free=free
        else:
            raise TypeError("free must be an int !")
    @property
    def total(self):
        return self._total
    @total.setter
    def total(self,total):
        #check si total est bien un int
        if type(total)==int:
            self._total==total
        else:
            raise TypeError("total must be an int !")
```

Classe `velo`

```
class velo:
    def __init__(self,statID,bikes,dis,free):
        self._time=int(time.time())
        self._statID=statID
        self._bikes=bikes
        self._dis=dis
        self._free=free
```

```
    #défintion des getter et setters des attributs
    @property
    def time(self):
        return self._time
    @time.setter
    def time(self,time):
        #check si time est bien un entier
        if type(time) == int:
            self._time == time
        else:
            raise TypeError("time type must be an int !")

    @property
    def statID(self):
        return self._statID
    @statID.setter
    def statID(self,statID):
        #check si statID est bien un entier
        if type(statID) == int:
            self._statID=statID
        else:
            raise TypeError("statID must be an int !")

    @property
    def bikes(self):
        return self._bikes
    @bikes.setter
    def bikes(self,bikes):
        #check si dis est bien un int
        if type(bikes)==int:
            self._bikes==bikes
        else:
            raise TypeError("bikes must be an int !")

    @property
    def dis(self):
        return self._dis
    @dis.setter
    def dis(self,dis):
        #check si dis est bien un int
        if type(dis)==int:
            self._dis==dis
        else:
            raise TypeError("dis must be an int !")

    @property
    def free(self):
        return self._free
    @free.setter
    def free(self,free):
        #check si free est bien un int
        if type(free) == int:
            self._free=free
```

```
        else:
            raise TypeError("free must be an int !")
```

Avec ces nouvelles classes, nous pouvons alors stocker les fichiers enregistrés sur des variables, stockables par la suite dans une base de données. Il n'est alors plus utile de stocker directement les fichiers. Je vais alors créer de nouvelles fonctions d'acquisition afin qu'elle ne renvoient plus un chemin d'accès vers un fichier mais un objet. Toutefois, mes fonctions de téléchargement de fichiers vont rester dans le module au cas où j'en aurais besoin dans la suite de la SAE. Je vais changer leurs noms pour `getParkFile` et `getVeloFile`. Ma fonction `getInfos` ne changera pas puisqu'elle n'est pas concernée directement par les nouvelles classes.

Code de la nouvelle fonction `getPark`

```
def getPark(idPark:str):

response=requests.get(f"https://data.montpellier3m.fr/sites/default/files/ressources/
{idPark}.xml") #Acquision du fichier xml du parking grâce à la variable idPark qui
renseigne l'identifiant du parking
    if not "Page non trouvée" in response.text: #On vérifie que le fichier récupéré
est bien un fichier valide et non une erreur 404
        tree = etree.fromstring(str(response.text).encode()) #Le contenu du fichier
récupéré est ensuite encodé en UTF-8 pour qu'il soit compris par la libraire lxml
puis mis sous forme d'élément Etree
        return parking(idPark,tree.xpath("Status")
[0].text=="Open",int(tree.xpath("Free")[0].text),int(tree.xpath("Total")[0].text))
#On crée et renvoie l'objet parking
```

Code de la nouvelle fonction `getVelo`

```
def getVelo():
    result=[] #Intialisation de la liste qui va contenir les objets velo, un objet
par station
    response=requests.get("https://montpellier-fr-
smoove.klervi.net/gbfs/en/station_status.json") #Acquisition du fichier json
représentant l'état de toutes les stations velaMag
    content=StringIO(response.text) #On convertit la chaine de caratéres du contenu
du fichier en chaine considérable comme un fichier pour l'utiliser avec la libraire
json
    content=json.load(content) #On load le fichier, il sera alors convertit en objets
itérables et donc utilisables
    for station in content["data"]["stations"]: #le dictionnaire data contient la
liste stations qui elle même contient les dictionnaires représentant chaque stations
        #On crée et ajoute l'objet vélo à la liste qui sera retournée en fin de
fonction

result.append(velo(int(station["station_id"]),int(station["num_bikes_available"]),int
(station["num_bikes_disabled"]),int(station["num_docks_available"])))
    return result #On renvoie la liste contenant l'état de chaque station.
```

Stockage des données

Pour stocker les données, je me suis orienté vers une base SQLite, facile d'utilisation avec python et un type de base avec laquelle j'ai déjà travaillé par le passé.

Il me faudra alors plusieurs tables

- Une table qui contiendra les acquisitions des parkings
- Une table qui contiendra les acquisitions des stations VeloMagg
- Une table pour mettre en relation les ids des stations VeloMagg avec leurs informations
- Une table pour mettre en relation les ids des pakings avec leurs informations
- Une table pour inscrire les informations des stations de tramway (utiles pour l'intérprétation des données)

Conception des tables

Table `infosPark`

id	name	lat	long
Identifiant du parking et clé primaire	Nom complet du parking	Latitude des coordonnées du parking	Longitude des coordonnées du parking
str	str	float	float

Nous donnant alors le code SQL suivant :

```
CREATE TABLE "infosPark" (
    "id"    TEXT,
    "name"    TEXT,
    "lat"    REAL,
    "long"    REAL,
    PRIMARY KEY("id")
);
```

Table `infosVelo`

id	name	lat	long	capacity
Identifiant de la station et clé primaire	Nom complet de la station	Latitude de la station	Longitude de la station	Capacité de la station
int	str	float	float	int

Nous donnant alors le code SQL suivant :

```
CREATE TABLE "infosVelo" (
    "id"    INTEGER,
    "name"    TEXT,
    "lat"    REAL,
    "long"    REAL,
    "capacity"    INTEGER,
```

```
    PRIMARY KEY("id")
);
```

Table `infosTram`

nom	lat	long
Nom de la station et clé primaire	Latitude de la sation	Longitude de la station
str	float	float

Nous donnant alors le code SQL suivant :

```
CREATE TABLE "infosTram" (
    "name"    TEXT,
    "lat"    REAL,
    "long"    REAL,
    PRIMARY KEY("name")
);
```

Il était nécessaire de faires ces trois tables en premier afin de pouvoir les lier avec les tables d'acquisition

Table `acquisPark`

idAcquis	time	idPark	free	total	occup
Clé primaire de la table	Heure d'acquisition epoch	Identifiant du parking	Nombre de places libres	Nombre de places total	Taux d'occupation du parking
int en Auto-incrémentation	int	str Clé étrangère: id de infosPark	int	int	float

Nous donnant alors le code SQL suivant :

```
CREATE TABLE "acquisPark" (
    "idAcquis"    INTEGER,
    "idPark"    TEXT,
    "free"    INTEGER,
    "total"    INTEGER,
    "occup"    REAL,
    FOREIGN KEY("idPark") REFERENCES "infosPark"("id") ON UPDATE CASCADE,
    PRIMARY KEY("idAcquis" AUTOINCREMENT)
);
```

Table `acquisVelo`

idAcquis	time	idStat	bikes	dis	free	total	occup

idAcquis	time	idStat	bikes	dis	free	total	occup
Clé primaire de la table	Heure d'acquisition epoch	Identifiant de la station VeloMagg	Nombre de vélos disponibles	Nombre de vélos non-disponibles	Nombre de docks libres	Nombre de docks total	Taux d'occupation de la station
int en Auto-incrémentation	int	int clé étrangère de idStat sur la table statVelo	int	int	int	int	int

Nous donnant alors le code SQL suivant :

```
CREATE TABLE "acquisVelo" (
    "idAcquis"    INTEGER,
    "time"    INTEGER,
    "idStat"    INTEGER,
    "bikes"    INTEGER,
    "dis"    INTEGER,
    "free"    INTEGER,
    "total"    INTEGER,
    "occup"    REAL,
    FOREIGN KEY("idStat") REFERENCES "infosVelo"("id") ON UPDATE CASCADE,
    PRIMARY KEY("idAcquis" AUTOINCREMENT)
);
```

Il me faut alors des fonctions pour enregistrer mes données dans ma base, je crée alors un deuxième module contenant mes fonctions d'enregistrement.

Enregistrement d'un objet de classe `parking`

Je connait la forme de ma requête d'insertion, il me suffit alors de créer une fonction qui crée la requête et l'exécute

```
def savePark(park:parking):
    #connection base
    connection = sq.connect("db.db")
    #Création curseur pour l'excécution de la requête
    cursor = connection.cursor()
    #Création de la requête sql
    query = f"""INSERT INTO acquisPark
    (time, idPark, free, total, occup)
    VALUES
    ({park.time},'{park.parkID}',{park.free},{park.total},{100-
(round(park.free/park.total,2))*100})
    """
    #Exécution de la requête
```

```
    cursor.execute(query)
    #Sauvegarde de la base avec modification
    connection.commit()
    #Fermeture des instances
    cursor.close()
    connection.close()
```

Enregistrement d'un objet de classe `velo`

De même que la fonction `savePark` je crée une fonction pour ma classe `velo`

```
def saveVelo(stat:velo):
    #connection base
    connection = sq.connect("db.db")
    #Création curseur pour l'excécution de la requête
    cursor = connection.cursor()
    #calcul du nombre total de places
    total = stat.free + stat.dis + stat.bikes
    #Création de la requête sql
    query = f"""INSERT INTO acquisVelo
    (time, idStat, bikes, dis, free, total, occup)
    VALUES
    ({stat.time},'{stat.statID}',{stat.bikes},{stat.dis},{stat.free},{total},{100-
(round(stat.free/total,2))*100})
    """
    #Exécution de la requête
    cursor.execute(query)
    #Sauvegarde de la base avec modification
    connection.commit()
    #Fermeture des instances
    cursor.close()
    connection.close()
```

Traitement des données

Le traitement des données se fera via python et GNUplot. Dans un premier temps, nous ferons des graphiques qui ne seront que sauvegardés en fichiers images.

Interprétation des données

Avant toute analyse, il sera important de prendre en compte le contexte de ces données. La capture à commencé le 19/01/2023 à 14h30 pour finir le 22/01/2023 à 10h51 Cela veut dire que dans le même temps, les manifestations et les grèves contre la réforme des retraites battaient leur plein Nos données proviennent donc d'un moment où le service des tramways était fortement perturbé, ou certains travailleurs ne se sont pas rendus à leur travail. En bref les données acquises ne représentent pas une utilisation habituelle des parkings et vélos de la ville. De plus, les données que nous avons ne nous garantissent pas l'exactitude de l'interprétation car nous ne connaisons pas les trajets des utilisateurs de parking et VéloMagg, encore moins pour les utilisateurs du Tram dont nous ne connaissons pas la fréquentation. Pour finir, nos données ne nous montrent que deux jours d'acquisitions. En bref, les données que nous allons interpréter ne prouvent rien. Notre interprétation sera alors surement fausse ou inexacte.

Plage de données

Dû à des erreurs de ma part, certains cas de figures n'ont pas été prévus pour êtres traités et ont causé des erreurs, causant par extension des coupures dans la capture de données. La plage de nos données est donc la suivante

- 19/01/2022, 14h29 et 25 secondes à 19/01/2022, 15h07 et 26 secondes
- 20/01/2022, 10h56 et 52 secondes à 22/01/2023, 10h51 et 58 secondes

Exclusion de données

Les données de la première plage ne portant que sur 30 minutes, elles ne sont pas suffisament significatives pour être traités, nous allons donc les supprimer

```
DELETE FROM acquisPark WHERE time < 1674208000
DELETE FROM acquisVelo WHERE time < 1674208000
```

Rappelons ensuite le travail demandé

- Etude du taux d'occupation des parkings voitures
- Etude du taux d'occupation des parkings vélos
- Etude du relai parking/velo

Je vais alors dupliquer ma base

Dans cette base dupliquée, je vais traiter mes données afin de réaliser l'étude sur le relai parking velo

Pour réaliser cette étude, je ne vais pas étudier certains parkings voitures et vélos car ces derniers ne sont pas signifiants

Seront donc exclus

- Les parkings proches de gares
- Les stations vélos qui sont en dehors d'un rayon de 250m d'un parking ou d'un arrêt de tram
- Inversement, les parkings en dehors d'un rayon de 250m d'une station VeloMagg ou d'un arrêt de tram

Excluant donc les parkings suivants

- Saint Roch
- Gare Montpellier Sud de France
- Vicarello

Et les stations VeloMagg suivantes

- Providence-Ovalie
- Celleneuve
- Jardin de La Lironde

Création des graphiques

Occupation des parkings voiture

Après plusieurs tests infructeux avec GNUplot et voyant le temps avant le rendu se réduire, je décide finalement d'abandonner gnuplot au profit de matplotlib, plus simple mais avec lequel j'ai l'habitude de travailler

Nous avons alors le graphique suivant

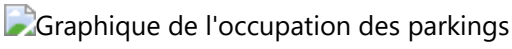 Graphique de l'occupation des parkings

On remaque alors que durant la plage d'enregistriment, il y a deux pics d'utilisations vers 21h et 16h30 On voit aussi que les parkings de Saint-Jean le Sec, du Corum et de la place de la Comédie sont les plus utilisés, atteignant parfois la capacité maximale

Malheureusemnt, par manque de temps, je n'ai pas pu aller plus loin dans les analyses de données